



Интро в курс. ML lifecycle. Метрики и функционалы потерь в задаче регрессии



ML

Машинное обучение


01



План лекции

- Про курс Machine Learning
- Процесс обучения ML-моделей
- Основные термины ML
- Метрики и функционалы потерь в задаче регрессии

Про курс Machine Learning



Для чего нужен курс



01


Узнаете про ключевые концепции машинного обучения, которые будете использовать в дальнейших курсах.

02

Научитесь применять алгоритмы на практике: kNN, линейную регрессию, бустинги и алгоритмы детекции аномалий.

03

Получите базовые знания в классическом ML. Про него чаще всего спрашивают на собеседованиях на ML-инженера/DS.



Этот курс — не про нейросети, он про базу. А без базы — никуда.

Как устроен курс



Блок 1. Основные термины машинного обучения и смежных областей.
Оценка качества моделей

- Ключевые понятия машинного обучения
- Метрики и функционалы потерь
- Различные способы оценок моделей

Блок 2. Линейные модели

- Линейная регрессия
- SVM
- Логистическая регрессия


Блок 3. Деревья решений и модели, основанные на них

- Обучение решающих деревьев и ансамблей, в том числе градиентных бустингов
- Узконаправленные подходы, в частности аплифт-моделирование

Блок 4. Обучение без учителя и работа с признаками


- Классические методы обучения без учителя
- Методы генерации и отбора признаков
- Интерпретация моделей

Процесс обучения ML-моделей



CRISP-DM

Cross-Industry Standard
Process for Data Mining



Современный ML Lifecycle



Схема решения задачи

01 Уточнение и постановка задачи (Problem Definition)

понимание бизнес-проблемы,
математическая формализация

02 Сбор, подготовка и анализ данных (Data Mining)

- понимание исходных данных
- сбор данных (Data collection)
- предобработка данных (Data cleaning) / подготовка данных для модели
- разведочный анализ (Exploratory Data Analysis)

Машинное обучение (Machine Learning)

03 Выбор

Алгоритма

- модели (Model selection)
- способа обучения: гиперпараметры, методы оптимизации

Контроля

- функции ошибки (Metric selection)
- способа контроля (разбиение train/test/valid)

Признаков

- генерация (Data coding = feature engineering)
- селекция (feature selection)

04 Обучение (fit)

05 Предсказание (predict) и проверка качества (evaluation)

(может ещё постобработка Post-processing)

06 Deploy / Release / Online evaluation / Debug / Monitoring / Maintenance

переобучаем алгоритм
на всех данных

07 Отчётность, презентация, коммуникация

визуализация данных,
модели, результатов

01

02

03

04

05

06

07

Уточнение и постановка задачи (Problem Definition)

Результат этапа

- Понимаем, какую бизнес-проблему решаем — и точно ли нужно использовать ML.
- Выясняем, какую бизнес-метрику оптимизируем.
- Связываем техническую метрику с бизнес-реалиями.
- Формализуем задачу: классификация/регрессия/ранжирование.
- Уточняем ограничения (время, технические ограничения) и пожелания (интерпретируемость).
- Продумываем, как будем использовать решение на практике и как оценивать успех: офлайн-метрики, A/B-тест, бизнес-индикаторы.

Сбор, подготовка и анализ данных (Data Mining)

Результат этапа

- Проверили, достаточно ли данных для решения задачи (объём, качество, доступность в проде).
- Учли особенности: дисбаланс классов, пропуски, выбросы, шум — знаем, как с ними работать.
- Провели ревизию данных: поняли смысл признаков, проверили валидность, зафиксировали потенциальные проблемы.
- Если данных нет — знаем, как и где их собирать (базы данных, API, логи, внешние источники).
- Продумали процесс разметки (если нужна): кто, как и чем проверяет качество.
- Провели очистку и подготовку данных: пропуски, выбросы, шум — не просто убрали, а осмыслили.
- Сделали EDA: поняли структуру данных, выявили зависимости, построили первичные гипотезы.
- Подготовили готовый датасет для модели и список гипотез/наблюдений для дальнейшей работы.

Выбор алгоритма, признаков и способа контроля модели

Результат этапа

Выбран алгоритм (Model Selection):

- Понимаем, какую модель используем и почему (учли ограничения по времени обучения, инференса, интерпретируемости, объёму данных).
- Не гонимся за модой, выбираем подходящий инструмент: часто это бустинг, но в ряде случаев — простые модели.

Определён способ оценки качества (Metric Selection):

- Чётко понимаем, какую метрику и Loss используем: что оптимизируем при обучении, что замеряем при валидации.
- Продумали способ валидации: Train/Test Split, k-Fold, Time Series Split — в зависимости от задачи.

Подготовлен набор признаков (Feature Engineering):

- Сгенерировали новые признаки, если нужно (например, из даты: день недели, час, is_weekend).
- Отобрали релевантные фичи, убрали лишнее, минимизировали шум.
- Проверили, нет ли Data Leakage (модель не должна «подглядывать» в будущее).

Есть план по обучению модели:

- Понимаем, как будут идти обучение, подбор гиперпараметров, сравнение моделей.
- Знаем, какие эксперименты будем проводить и какие вопросы они должны закрыть.

Обучение модели (Fit)

Результат этапа

- Модель обучена на данных.
- Используем только те признаки, которые реально доступны в проде, чтобы не было странных моментов на тестах.
- Обучение идёт с учётом валидации и контроля переобучения:
 - Следим за поведением метрик на обучении/валидации.
 - Проверяем, не случилась ли утечка данных (Data Leakage).
 - Отслеживаем переобучение (например, сильный провал на тесте).
- Сравниваем разные модели/подходы: иногда простая модель работает лучше сложной, важно это проверить.
- Итеративно дорабатываем пайплайн, если нужно: возвращаемся к признакам, алгоритму, настройкам.

01

02

03

04

05

06

07

Предсказания и оценка качества (Predict & Evaluation)

Результат этапа

- Провели честную оценку модели: предсказания делаем только на новых данных.
- Считаем метрики по плану, заранее выбранному (не подстраиваем метрики под результат постфактум).
- Сравнили с бейзлайном: новая модель действительно лучше?
- Связали ML-метрики с бизнес-метриками: понимаем, как увеличение точности влияет на деньги/процесс.
- Оценили устойчивость модели: нет ли случайных всплесков качества из-за удачного разбиения данных?
- Подумали, нужна ли постобработка предсказаний: сглаживание, калибровка, кастомные правила.
- Проверили, совпадает ли результат с ограничениями и планами, зафиксированными на этапе постановки задачи.

01

02

03

04

05

06

07

Deploy / Release / Online Evaluation / Debug / Monitoring / Maintenance

Результат этапа

- Модель готова к продакшену: перевели из ноутбука в реальную систему (через API, пайплайны, ML-сервисы).
- Переобучили модель на всех доступных данных перед релизом — чтобы использовать максимум информации.
- Настроен мониторинг: следим за качеством предсказаний, скоростью, стабильностью работы.
- Готовы к отладке и поддержке: предусмотрены логи, алёрты на подозрительное поведение.
- Понимаем, что модель устаревает — есть план регулярного переобучения или обновления.
- Учили инфраструктуру: договорились, кто за что отвечает при работе модели.

01

02

03

04

05

06


07

Отчётность, презентация, коммуникация, документация

Результат этапа

- Готова презентация результатов: понятно объясняем, что сделали, зачем и что это даёт бизнесу.
- Показали не только результат, но и контекст: как работала модель, какие были ограничения, каковы риски.
- Оформлена документация: что делали, какие гипотезы проверяли, какие решения принимали и почему.
- Визуализация: графики, дашборды, инфографика, чтобы показать не только «что получилось», но и «почему».
- Провели коммуникацию с командой и заказчиком: согласовали результат, поняли, нужны ли доработки.
- Обсудили дальнейшие шаги: нужен ли релиз, итерации, поддержка, следующий этап развития модели.

Основные термины ML



Пространство объектов X

Пространство меток Y

Целевая функция $y(x)$



Примеры объектов $x \in X$

- пациенты
- клиенты банка
- месторождения
- описания проектов
- описания недвижимости

observation / example / instance / object

Примеры меток $y \in Y$

- {здоров, грипп, ангина, ковид}
- {мошенник, честный}
- {есть золото, нет золота}
- доход от реализации
- стоимость

target / response / outputs / dependent variable

Есть неизвестная целевая зависимость $y(x): X \rightarrow Y$

Задача обучения с учителем



Дано

Обучающая выборка —
конечное множество объектов
с известными метками.

$$X_{\text{train}} = \{(x_1, y_1), \dots, (x_m, y_m)\}$$


$$y(x_1) = y_1$$


...

$$y(x_m) = y_m$$



Найти

Алгоритм  — способ оценивать
метки на новых объектах.



Цели решения ML задачи



01

Восстановление целевой зависимости

Уметь восстанавливать метки новых объектов $y(x)$ — найти зависимость целевой переменной от остальных.

02

Интерпретация

Как устроена $y(x)$.

03

Оценка качества полученного решения

Например, насколько ошибаемся в среднем, что ждать при использовании нашего прогноза.

Типы задач обучения с учителем



Классификация (Classification)

$$|Y| = k \ll \infty$$

Бинарная

$$Y = \{0, 1\} \text{ или } Y = \{-1, +1\}$$

Скоринговая бинарная

$$a(x) \in [0, 1]$$

На k непересекающихся классов (Multiclass Classification)

$$Y = \{1, 2, \dots, k\}$$

На k пересекающихся классов (Multilabel Classification)

$$Y = \{0, 1\}^k$$

Регрессия (Regression)

$$Y = \mathbb{R}$$

Многомерная регрессия

$$Y = \mathbb{R}^l$$

Прогнозирование (Forecasting)

$$X_{\text{train}} = \{(x_1, t_1, y_1), \dots, (x_m, t_m, y_m)\}$$

$$t_1 \leq t_2 \leq \dots \leq t_m$$

Пространство объектов



Например:

- медицинские истории
- тексты
- сигналы / временные ряды / последовательности изображения
- векторы / множества / графы
- ...

Для удобства последующих рассуждений:

$X = \mathbb{R}^n$ — n -мерное признаковое пространство.

$x_i = (x_{i1}, \dots, x_{in})$ — объект в признаковом описании.

x_{ij} — j -й признак.

inputs / attributes / regressors / properties /
covariates / features / variables

Задача в признаковой постановке



Матрица «объект — признак» (Data Matrix).



описание
объекта



класс объекта
(целевая переменная)

номер клиента	пол	возраст	поведение_30–59_дней	debt_ratio	доход	вернёт кредит?
0	М	46	0	1.329588	800.0	0
1	Ж	69	0	0.535122	3800.0	1
2	М	77	0	0.169610	3000.0	0
3	М	58	1	2217.000000	NaN	0
4	X ₄₁	X ₄₂	X ₄₃	X ₄₄	X ₄₅	Y ₄

ПО СТРОКАМ

Признаковые описания объектов

ПО СТОЛБЦАМ

Значения конкретных признаков

Целевой признак



Target


Задачи классификации — целевой признак категориальный.


Задачи регрессии — целевой признак вещественный.

Целевой признак может быть любым.
Например, графом!


Замечание

Целевой признак «условен».
Часто просто дана матрица
(целевой признак приходится формировать).





Метрики и функционалы потерь в задаче регрессии



Метрики и функционалы потерь



ML-метрика — это способ количественно оценить качество работы модели, сравнивая её предсказания с истинными значениями.


Функционал потерь (Loss Function / лосс / Loss) — это формализованная функция ошибки, которую модель оптимизирует во время обучения.

Метрику нужно выбирать с учётом целей и контекста применения модели.


Метрики используют:

- во время валидации и тестирования;
- при сравнении нескольких моделей или конфигураций;
- в процессе мониторинга качества модели в production-среде.

Именно Loss сообщает алгоритму, насколько «плохо» текущее предсказание и как нужно обновить параметры/веса модели.



Метрики и функционалы потерь в задаче регрессии



Здесь:

- **функционалы потерь** — функции, на которых можно напрямую обучать модель;
- **метрики** — те индикаторы, которые стоит замерять для представления результатов бизнесу.

Рабочий пример



Объекты	$\hat{y}_i$, Прогноз млн ₹	y_i , Факт млн ₹	$y_i - \hat{y}_i$, Ошибка, млн ₹.
Коммуналка	5	4	-1
Студия	5	6	+1
Однокомнатная	8	10	+2
Двухкомнатная	12	16	+4

Хотим получить одно число,
которое будет характеризовать
качество работы модели.

Обозначения




y_i — истинное значение таргета для объекта i

$\hat{y}_i$ — предсказание модели для объекта i

n — количество наблюдений (объектов в выборке)

$\bar{y}$ — среднее значение таргета по всем объектам



MAE: средний абсолютный размер ошибки

Mean Absolute Error

ФП

Метрика


$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Преимущества

- Легко интерпретировать.
- Измеряется в единицах таргета.
- Удобна, когда все ошибки нужно учитывать равномерно

Недостатки

- Крупные ошибки не получают дополнительного усиления.
- Не показывает направление ошибки.
- Как loss негладкая в нуле, поэтому менее удобна для градиентной оптимизации



Для нашего рабочего примера:

$$\begin{aligned} \text{MAE} &= \frac{|4 - 5| + |6 - 5| + |10 - 8| + |16 - 12|}{4} \\ &= \frac{|-1| + |1| + |2| + |4|}{4} \\ &= \frac{1 + 1 + 2 + 4}{4} \\ &= 2 \text{ млн } \text{Р} \end{aligned}$$

В среднем модель ошибается на **2 млн Р**.

MSE: средний квадрат ошибки



Mean Squared Error

ФП

Метрика


$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Преимущества

- Сильнее штрафует крупные ошибки.
- Гладкая и дифференцируемая, поэтому удобна как loss.

Недостатки

- Чувствительна к выбросам.
- Сложнее интерпретировать, чем MAE.
- Измеряется в квадрате единиц таргета.



Для нашего рабочего примера:

$$\begin{aligned} \text{MSE} &= \frac{(4 - 5)^2 + (6 - 5)^2 + (10 - 8)^2 + (16 - 12)^2}{4} \\ &= \frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{4} \\ &= \frac{1 + 1 + 4 + 16}{4} \\ &= 5.5 \text{ (млн Р)}^2 \end{aligned}$$

MAE и MSE: оптимальные константы



Есть выборка из пяти объектов без признаков: $y=[1,2,3,4,100]$.

Мы можем предсказать всем объектам только одно и то же число c . Какое значение выбрать?

$$L(c) = \frac{1}{n} \sum_{i=1}^n (y_i - c)^2$$

MAE и MSE: оптимальные константы



Есть выборка из пяти объектов без признаков: $y=[1,2,3,4,100]$.


Мы можем предсказать всем объектам только одно и то же число c . Какое значение выбрать?

Решение:

$$L(c) = \frac{1}{n} \sum_{i=1}^n (y_i - c)^2$$

$$L'(c) = \frac{2}{n} \sum_{i=1}^n (c - y_i) = 2c - \frac{2}{n} \sum_{i=1}^n y_i$$

$$L'(c) = 0 \implies c = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y}$$



MAE и MSE: оптимальные константы



$$c_{\text{MSE}}^* = \arg \min_c \frac{1}{n} \sum_{i=1}^n (y_i - c)^2 = \bar{y} = \frac{1 + 2 + 3 + 4 + 100}{5} = 22$$

$$c_{\text{MAE}}^* = \arg \min_c \frac{1}{n} \sum_{i=1}^n |y_i - c| = \text{median}(y) = 3$$

Выбор loss определяет, что учится предсказывать модель: MAE ведёт к медиане, MSE — к среднему.

Huber Loss: MSE для малых ошибок, MAE для больших

ФП

$$\text{Huber}_\delta = \frac{1}{n} \sum_{i=1}^n \begin{cases} \frac{1}{2}(y_i - \hat{y}_i)^2, & |y_i - \hat{y}_i| \leq \delta, \\ \delta \left(|y_i - \hat{y}_i| - \frac{\delta}{2} \right), & |y_i - \hat{y}_i| > \delta. \end{cases}$$


δ — порог переключения: при ошибке до δ штраф квадратичный, после δ — линейный

Преимущества

- Менее чувствительна к выбросам, чем MSE.
- Дифференцируема во всех точках, поэтому удобна для градиентной оптимизации.
- Сочетает свойства MSE и MAE: квадратична для малых ошибок и линейна для больших.

Недостатки

- Нужно подбирать порог δ ; он зависит от масштаба таргета.
- Сложнее интерпретировать и объяснять, чем MAE или RMSE.



$$\begin{aligned} \text{Huber}_1 &= \frac{1}{4} \left(\frac{1}{2}(4-5)^2 + \frac{1}{2}(6-5)^2 + \left(|10-8| - \frac{1}{2} \right) + \left(|16-12| - \frac{1}{2} \right) \right) \\ &= \frac{0.5 + 0.5 + 1.5 + 3.5}{4} \\ &= 1.5 \text{ (млн } \text{₹)}^2 \end{aligned}$$

При $\delta = 1$ ошибки до 1 млн ₹ штрафуются квадратично, большие ошибки — линейно



Quantile Loss: разная цена недопрогноза и перепрогноза

ФП

$$QL_{\tau} = \frac{1}{n} \sum_{i=1}^n \begin{cases} \tau (y_i - \hat{y}_i), & y_i \geq \hat{y}_i, \\ (1 - \tau)(\hat{y}_i - y_i), & y_i < \hat{y}_i. \end{cases}$$


- $\tau = 0.5$ — штрафы симметричны;
- $\tau > 0.5$ — сильнее штрафует недопрогноз;
- $\tau < 0.5$ — сильнее штрафует перепрогноз.

Когда использовать

- Цена недопрогноза и перепрогноза различается.
- Нужен прогноз с запасом вверх или вниз.
- Примеры: спрос, запасы, финансовые риски.

Что важно помнить

- τ задаёт квантиль, который предсказывает модель.
- τ выбирают исходя из бизнес-цены ошибок.



$$\begin{aligned} \widetilde{QL}_{\frac{2}{3}} &= 3QL_{\frac{2}{3}} = \frac{1}{4} (|4 - 5| + 2|6 - 5| + 2|10 - 8| + 2|16 - 12|) \\ &= \frac{1 + 2 + 4 + 8}{4} = 3.75 \text{ млн } \text{Р} \end{aligned}$$

При $\tau = \frac{2}{3}$ занижение штрафует в два раза сильнее завышения

* Для удобства визуализации Quantile Loss умножен на 3.
Умножение на положительную константу не меняет точку минимума.



RMSE: корень из среднего квадрата ошибки

Root Mean Squared Error

Метрика

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} = \sqrt{\text{MSE}}$$

Преимущества

- Измеряется в единицах таргета.
- Проще интерпретировать, чем MSE.
- Сильнее учитывает крупные ошибки, чем MAE.

Недостатки

- Чувствительна к выбросам.
- Менее устойчива, чем MAE.
- Не показывает распределение ошибок: одинаковый RMSE могут дать одна крупная или много небольших ошибок.

Для нашего рабочего примера:

$$\begin{aligned} \text{RMSE} &= \sqrt{\text{MSE}} \\ &= \sqrt{\frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{4}} \\ &= \sqrt{\frac{1 + 1 + 4 + 16}{4}} \\ &= \sqrt{5.5} \\ &\approx 2.35 \text{ млн } \text{₹} \end{aligned}$$

Корень из среднего квадрата ошибки равен 2.35 млн ₹.

После извлечения корня возвращаемся из $(\text{млн } \text{₹})^2$ в млн ₹.

R^2 : сравнение модели с константным бейзлайном



Коэффициент детерминации

Метрика

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

← сумма квадратов ошибок модели (~MSE).
← сумма квадратов ошибок самой простой модели, которая всегда возвращает среднее значение $\bar{y}$

Как читать:

- $R^2 = 1$ — идеальное предсказание.
- $R^2 = 0$ — модель не лучше константного бейзлайна.
- $R^2 < 0$ — модель хуже бейзлайна.
- **Диапазон:** от $-\infty$ до 1.

Для нашего рабочего примера:

Шаг 1: считаем среднее значение таргета $\bar{y}$

$$\bar{y} = \frac{4 + 6 + 10 + 16}{4} = 9$$

Шаг 2: считаем R^2

$$\begin{aligned} R^2 &= 1 - \frac{(4 - 5)^2 + (6 - 5)^2 + (10 - 8)^2 + (16 - 12)^2}{(4 - 9)^2 + (6 - 9)^2 + (10 - 9)^2 + (16 - 9)^2} \\ &= 1 - \frac{(-1)^2 + (1)^2 + (2)^2 + (4)^2}{(-5)^2 + (-3)^2 + (1)^2 + (7)^2} \\ &= 1 - \frac{1 + 1 + 4 + 16}{25 + 9 + 1 + 49} \\ &= 1 - \frac{22}{84} \\ &\approx 0.74 \end{aligned}$$

$R^2 = 0.74$: модель объясняет качество заметно лучше, чем константный бейзлайн, который всегда предсказывает среднее.

MAPE: средняя абсолютная процентная ошибка

Mean Absolute Percentage Error Метрика

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Преимущества

- Легко интерпретировать и объяснять бизнесу.
- Не зависит от единиц измерения таргета.
- Удобна для сравнения относительной точности на объектах разного масштаба.

Недостатки

- Не определена при $y_i = 0$.
- Нестабильна при значениях таргета, близких к нулю.
- Может переоценивать ошибки на объектах с маленьким y_i .

Для нашего рабочего примера:

$$\begin{aligned} \text{MAPE} &= \frac{1}{4} \left(\frac{|4 - 5|}{4} + \frac{|6 - 5|}{6} + \frac{|10 - 8|}{10} + \frac{|16 - 12|}{16} \right) \cdot 100\% \\ &= \frac{1}{4} \left(\frac{1}{4} + \frac{1}{6} + \frac{2}{10} + \frac{4}{16} \right) \cdot 100\% \\ &= \frac{25\% + 16.7\% + 20\% + 25\%}{4} \\ &\approx 21.7\% \end{aligned}$$

В среднем прогнозы модели отличаются от истинных значений на 21.7%.

RMSLE, sMAPE, WAPE



Метрика

RMSLE (Root Mean Squared Logarithmic Error) — корень из средней квадратичной ошибки между логарифмами предсказаний и реальных значений.

$$\text{RMSLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(1 + \hat{y}_i) - \log(1 + y_i))^2}$$

sMAPE (Symmetric Mean Absolute Percentage Error) — процентная ошибка MAPE, но **симметричная** по отношению к истинным и предсказанным значениям.

$$\text{sMAPE} = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

WAPE (Weighted Absolute Percentage Error) — отношение суммы абсолютных ошибок к сумме абсолютных истинных значений.

$$\text{WAPE} = \frac{\sum |\hat{y}_i - y_i|}{\sum |y_i|} \times 100\%$$

Пример расчета метрик и функционалов потерь




Объекты
Кommunalка
Студия
Однокомнатная
Двухкомнатная

$\hat{y}_i$, Прогноз млн ₹	y_i , Факт млн ₹
5	4
5	6
8	10
12	16

$y_i - \hat{y}_i$, Ошибка, млн ₹.
-1
+1
+2
+4

$$\begin{aligned} \text{MAE} &= 2 \text{ млн ₹} \\ \text{MSE} &= 5.5 (\text{млн ₹})^2 \\ \text{Huber}_{\delta=1} &= 1.5 (\text{млн ₹})^2 \\ L_{\tau=\frac{2}{3}} &= 3 \text{QL}_{\frac{2}{3}} = 3.75 \text{ млн ₹} \\ \text{RMSE} &\approx 2.35 \text{ млн ₹} \\ R^2 &\approx 0.74 \\ \text{MAPE} &\approx 21.7\% \\ \text{MSLE} &\approx 0.0423 \\ \text{RMSLE} &\approx 0.206 \\ \text{sMAPE} &\approx 22.8\% \\ \text{WAPE} &\approx 22.2\% \end{aligned}$$

Карта ФП и метрик регрессии



Применение метрик и ФП регрессии



Самые часто встречающиеся кейсы

Название	Формула	Когда использовать
MAE (Mean Absolute Error)	$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Когда важна равномерная оценка всех ошибок и устойчивость к выбросам
MSE (Mean Squared Error)	$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$	Если нужно сильнее штрафовать крупные ошибки
RMSE (Root Mean Squared Error)	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Когда важно сохранить масштаб целевой переменной
R² (коэффициент детерминации)	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$	Когда нужно понять, насколько хорошо модель объясняет поведение целевой переменной
MAPE (Mean Absolute Percentage Error)	$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $	Когда нужно представить бизнесу результат в понятной форме или если в целевой переменной нет значений, близких к нулю

Пример подбора ФП и метрики регрессии



Кейс 1. Прогноз времени доставки из магазина у дома

Предсказываем длительность доставки заказа в минутах для внутреннего планирования курьеров.

- Ошибки в обе стороны одинаково нежелательны.
- Особенно важно избегать крупных промахов.
- Качество нужно оценивать в минутах.

Кейс 2. Прогноз спроса на товары в магазине

Предсказываем спрос на товар на следующий день, чтобы сформировать заказ поставщику.

- Недопрогноз приводит к отсутствию товара и потерянным продажам.
- Перепрогноз приводит к излишкам на складе.
- Недопрогноз обходится примерно в четыре раза дороже.

Кейс 3. Прогноз месячной выручки магазинов

Предсказываем выручку магазинов разных форматов: от небольших точек до гипермаркетов.

- Выручка магазинов различается в десятки раз.
- Важнее относительная ошибка, а не ошибка в рублях.
- Значения таргета положительны, редкие крупные магазины не должны определять всё обучение.

Пример подбора ФП и метрики регрессии



Кейс 1. Прогноз времени доставки из магазина у дома

Предсказываем длительность доставки заказа в минутах для внутреннего планирования курьеров.

- Ошибки в обе стороны одинаково нежелательны.
- Особенно важно избегать крупных промахов.
- Качество нужно оценивать в минутах.

- **ФП: MSE**
Сильнее штрафует крупные ошибки.
- **Метрика: RMSE**
Показывает ошибку в минутах.

Кейс 2. Прогноз спроса на товары в магазине

Предсказываем спрос на товар на следующий день, чтобы сформировать заказ поставщику.

- Недопрогноз приводит к отсутствию товара и потерянным продажам.
- Перепрогноз приводит к излишкам на складе.
- Недопрогноз обходится примерно в четыре раза дороже.

- **ФП: Quantile Loss, $\tau = 0.8$**
Недопрогноз штрафуются в 4 раза сильнее.
- **Метрика: WAPE**
Показывает суммарную ошибку относительно общего спроса.

Кейс 3. Прогноз месячной выручки магазинов

Предсказываем выручку магазинов разных форматов: от небольших точек до гипермаркетов.

- Выручка магазинов различается в десятки раз.
- Важнее относительная ошибка, а не ошибка в рублях.
- Значения таргета положительны, редкие крупные магазины не должны определять всё обучение.

- **ФП: MSLE**
Ориентируется на относительные ошибки и снижает влияние масштаба магазина.
- **Метрика: RMSLE**
Сравнивает качество в логарифмической шкале.
- **Дополнительно: MAPE**
Даёт понятную бизнесу ошибку в процентах.

Итог. Метрики и функционалы потерь регрессии



Функционал потерь задаёт цель обучения: выбор loss определяет, что именно будет предсказывать модель.

Метрика оценивает качество модели, а одну и ту же функцию иногда используют и как loss, и как метрику.

Универсально лучшего ФП и метрики нет: выбор зависит от масштаба таргета, выбросов и цены разных типов ошибок.

MAE устойчивее к крупным ошибкам, MSE и RMSE сильнее их штрафуют, Huber сочетает оба подхода.


Для относительных и асимметричных ошибок нужны специальные функции: MAPE/RMSLE учитывают масштаб, Quantile Loss — разную цену недопрогноза и перепрогноза.

Про курс


Про процесс создания моделей

Функционалы потерь и метрики регрессии

- Курс — про классический ML, без нейросетей.
При этом многие термины и методы затем будут использоваться в DL.
- Основная цель — понимать и уметь применять алгоритмы: от kNN и линейной регрессии до бустингов, глубокой работы с фичами и временными рядами.
- Это база для практики, собеседований и следующих курсов.



- CRISP-DM — база, но в реальной работе pipeline шире: нужно учитывать ограничения в проде, переобучение, поддержку.
- ML-процесс — итеративный: часто возвращаемся к данным, признакам, задаче.
- Качество решения = данные + метрики + бизнес-ограничения, не просто «подобрать модель».
- ML без связи с бизнесом — бесполезен, даже если метрики отличные.



- Метрика $\neq$ Loss.
Метрика нужна для оценки качества, Loss — для обучения. Они не всегда совпадают.
- Выбор метрики зависит от задачи: нет лучшей метрики для всех случаев.

Ключевые метрики и ФП

- **MAE** — средняя абсолютная ошибка, устойчива к выбросам.
- **MSE/RMSE** — сильнее штрафуют большие ошибки, чувствительны к выбросам.
- **R²** — показывает, насколько модель лучше простого предсказания среднего.
- **RMSLE** — полезен, когда важны относительные отклонения.
- **MAPE/sMAPE/WAPE** — процентные метрики, удобны для бизнеса, но могут вести себя нестабильно при малых значениях.



Вопросы

